

Geometry-Guided Feed-Forward Regression for LiDAR-Inertial-Camera Photo-Realistic 2DGS Mapping

摘要—增量式三维场景重建要求系统在逐帧接收新观测的同时持续扩展地图，而有限的在线优化预算使得新插入高斯的初始属性质量直接影响地图的累积效果。现有基于 3D Gaussian Splatting 的增量式建图系统在表示与初始化两方面仍存在不足：三维椭球原语缺乏显式的表面法线语义，基于规则的初始化策略也难以充分利用外部几何先验。针对这两个相互关联的问题，本文提出了一种面向增量式 2DGS 场景重建的上下文感知前馈高斯回归系统。系统以 2DGS surfel 为地图基础表示，融合 SPNet 深度补全与单目法线先验构造候选点及其几何方向；前馈回归网络通过跨注意力机制聚合当前帧与历史帧的图像-渲染上下文，并以法线先验为锚点经 Gram-Schmidt 正交化构造 surfel 旋转，在单次前向传播中直接预测完整的 surfel 属性。网络训练通过自蒸馏训练完成，无需外部标注数据集。在 R3LIVE 和 MCD 数据集上的实验表明，本文方法在全部测试序列上均优于现有基线，较最近的多传感器增量高斯建图基线平均提升 1.28 dB PSNR；消融实验进一步验证了前馈回归器在有限优化预算下对新高斯早期收敛质量的稳定改善。

I. INTRODUCTION

增量式三维场景重建在自动驾驶、灾害救援、工业巡检和文化遗产保护等时效性强的现场任务中扮演着关键角色。这类应用要求系统在持续接收新观测的同时，逐步积累几何一致且外观逼真的三维地图。尤其在自动驾驶领域，高斯表示已被用作三维占据感知与闭环驾驶仿真的场景中间表示，使得在线重建的地图质量直接关系到下游感知与规划的可靠性。然而，在线系统的运行约束决定了每帧可供地图优化的计算预算十分有限，新插入的地图元素往往只能经历少量优化便需服务于后续帧的渲染与决策。因此，新元素在插入时的初始质量直接影响整张地图的累积效果。

3D Gaussian Splatting (3DGS) 凭借显式高斯原语和高效可微光栅化，在渲染速度与优化效率上展现出显著优势，已成为在线照片级建图的主流表示。近年来，多传感器融合的增量式高斯建图系统进一步将 LiDAR、IMU 与相机的互补观测整合到统一的高斯地图中，在

大尺度室外场景下验证了渲染质量与在线稳定性的可行性。

尽管如此，现有系统的地图后端在表示与初始化两方面仍存在提升空间，且二者相互关联。在表示层面，标准 3DGS Splatting 在像素光线 (pixel ray) 与三维椭球原语的相交处评估高斯基函数的值，限制了深度渲染的几何一致性，也使得单目法线估计等几何先验难以与地图表示直接耦合；2D Gaussian Splatting (2DGS) 已通过将高斯压缩为二维有向盘面 (surfel) 在几何质量上取得显著进步，但尚未被引入增量式建图场景。在初始化层面，当前系统通常采用基于规则的初始化策略为新高斯赋予初始属性，导致新高斯需要较多在线优化步数才能收敛到合理状态，与增量式系统有限的逐帧优化预算形成矛盾。虽然已有系统引入深度补全网络缓解 LiDAR 覆盖不足，但学习型先验仅被用于确定补点位置，尚未扩展到高斯属性的全面预测；而 pixelSplat、MVSplat 等前馈方法虽已在离线场景中验证了从图像特征直接回归高斯属性的可行性，其设计面向的是一次性重建而非逐帧增量建图。归结而言，若表示本身缺乏几何可解释性，基于规则的初始化便难以有效利用外部几何先验；而缺少学习型属性预测，几何可解释表示的优势也无法在插入阶段充分兑现。

针对上述问题，本文提出了一种面向增量式 2DGS 场景重建的上下文感知前馈高斯回归系统。系统以 2DGS surfel 为地图基础表示，在外部 LIVO 前端提供位姿的条件下，通过融合深度补全与单目法线先验构造初始点及几何先验输入 $\mathbf{g}$ ，并联合利用当前帧与滑动窗口内历史帧的图像与渲染特征构造的多视角上下文特征输入 $\mathbf{ctx}$ ，使得前馈回归网络能在单次前向传播中直接预测新高斯的完整 surfel 属性，随后纳入在线光度优化迭代。该系统还包含一套完整的自蒸馏训练方法，使前馈网络能在无需外部标注数据集的条件下完成

训练和部署。

本文的主要贡献如下：

- 基于 2DGS surfel 的几何感知增量式高斯地图后端。不同于现有以 3DGS 体高斯为默认表示的增量式系统，本文以 2DGS 的表面化表示为基础，围绕 surfel 的法线语义构建了融合 SPNet 深度补全与 DA3 法线先验的统一几何管线，并通过深度畸变与法线一致性约束驱动地图更新，为后续的前馈高斯插入方法提供了几何可解释的表示基础。
- 上下文感知的前馈高斯插入方法。本文提出一种用于替代传统基于规则初始化的前馈高斯属性回归方法。该方法以每个候选点的多视角上下文特征输入 ctx 和几何先验输入 $\mathbf{g}$ 为基础，通过逐点跨注意力融合上下文，并以 DA3 法线先验为锚点、经 Gram-Schmidt 正交化构造 surfel 旋转，在单次前向传播中直接回归完整的 2DGS surfel 属性。
- 面向在线增量建图的自蒸馏训练。本文构建了一套使前馈插入方法在无需外部标注数据集条件下完成训练的自蒸馏管线。该方法以高斯为核心单位构造训练样本，以达到指定训练次数时的高斯快照作为监督信号，并在该时刻同步采集上下文特征输入 ctx 与几何先验输入 $\mathbf{g}$ ，实现从在线建图、离线训练到重新部署的自增强过程。

II. RELATED WORKS

NeRF 及后续辐射场方法验证了照片级新视角合成的有效性，但体渲染采样开销较高，不适合作为逐帧在线更新的直接地图后端。3D Gaussian Splatting 通过显式高斯原语和可微光栅化显著提高了渲染效率，并被 MonoGS、GS-SLAM、SplaTAM、Photo-SLAM 等在线系统用于持续建图。然而，这些系统大多仍以 3DGS 体高斯为基础，新高斯通常依赖深度、点间距或协方差等规则初始化；在在线优化步数有限时，初始化误差会影响新插入区域的早期渲染质量和地图累积稳定性。

为提升高斯地图的几何一致性，2D Gaussian Splatting、GaussianSurfels 和 PGSR 等方法将高斯表示进一步表面化，通过二维 surfel、深度畸变约束和法线一致性约束改善表面贴合能力。这类工作说明，显式表面方向比 3D 椭球更适合承载深度和法线等几何先验。但现有表面化高斯方法主要面向离线或静态重建，尚未系统讨论在增量式系统中如何筛选新点、初始化完整 surfel 属性，并在少量在线优化内快速融入地图。

在大尺度户外场景中，LiDAR-Inertial-Camera 融合为增量式高斯建图提供了更稳定的位姿和几何观测。Gaussian-LIC 利用 LiDAR 点和视觉三角化点初始化 3DGS 地图，GS-LIVM 与 GS-LIVO 进一步考虑稀疏 LiDAR、局部窗口优化和资源约束，Gaussian-LIC2 则引入深度补全先验改善高斯初始化。这些工作与本文问题设定最接近，但它们仍主要采用 3DGS 后端，学习型先验也多用于补点或补深度，没有进一步预测尺度、方向、颜色和不透明度等完整属性。本文在 LIVO 前端提供位姿的条件下，将 2DGS surfel 作为地图表示，并通过前馈网络一次性预测新 surfel 的完整属性，从而改善增量插入阶段的初始质量

III. METHOD

A. 系统概述

本系统是一个基于外部位姿前端增量式 2DGS 场景重建后端。系统接收外部 LiDAR-Inertial-Camera 前端（如 R3Live）实时输出的同步数据流，每帧包含 RGB 图像、稀疏 LiDAR 点云和 6-DOF 相机位姿，以 2DGS surfel 为基础地图表示。整体流程如图 X 所示。

当新关键帧到达时，系统首先将稀疏 LiDAR 点投影到图像平面形成稀疏深度图，经 SPNet 深度补全后在 LiDAR 盲区生成补充初始 3D 点；与此同时，DA3 单目深度估计模型预测稠密深度并与 LiDAR 对齐，由此为初始点提供法线先验。在初始点生成后，系统对当前高斯地图进行渲染，依据渲染透明度和颜色误差识别欠重建区域，并结合颜色梯度过滤与体素下采样，从中筛选出确需新增高斯的候选点子集。筛选后的候选点被组织为回归器的两类输入，即上下文特征输入 ctx 与几何先验输入 $\mathbf{g}$ ，并送入前馈回归网络。该网络通过跨注意力机制融合多视角上下文，在单次前向传播中直接回归每个候选点的完整 surfel 属性。预测的新高斯插入地图后，系统在滑窗内的关键帧上进行多轮在线优化，以光度损失 ($L1 + SSIM$) 与 2DGS 几何约束损失 (深度畸变 + 法线一致性) 联合驱动高斯属性收敛。非关键帧仅接收位姿而不触发地图扩展。

前馈回归网络的训练通过自蒸馏训练完成。系统首先以 **naive** 模式（不使用前馈网络，采用传统的基于规则初始化）在训练场景上运行一遍完整的增量式建图；当某帧新增高斯的累积训练次数达到预设阈值后，系统快照其当前属性，并在该时刻构造对应的上下文特征输




图 1. 系统整体流程。(A) 外部 LiDAR-惯导-视觉前端提供同步的 RGB 图像、LiDAR 观测、IMU 信息和相机位姿。(B) 系统利用 SPNet 深度补全和 DA3 法线估计生成稠密几何先验，并与 LiDAR 点共同形成欠重建区域的初始点。(C) 对于每个候选点，前馈高斯回归器聚合逐点对齐的多视图上下文，直接预测完整的 2DGS surfel 属性。(D) 预测得到的新 surfel 被插入增量地图后，再结合在线优化进一步更新；同时，当前地图的渲染结果继续作为后续插点的上下文输入。

入 ctx 与几何先验输入 $\mathbf{g}$ ，形成训练样本，随后离线训练前馈网络。

B. 稠密几何先验

采用 SPNet 轻量级深度补全网络将 RGB 图像与稀疏 LiDAR 深度融合为稠密深度图，并在无 LiDAR 覆盖的区域采样补充 3D 初始点。最终，SPNet 补充点与原始 LiDAR 投影点合并构成初始点集。

使用 DA3 对当前帧 RGB 图像推理输出相对深度图后，系统通过最小二乘仿射对齐将其与稀疏 LiDAR 深度配准，得到与真实尺度一致的稠密深度图，再以中心差分计算逐像素法线。按初始点的像素坐标在法线图上采样，得到每个初始点的相机空间法线 $\mathbf{n}_{\text{cam}} \in \mathbb{R}^3$ 。

需要指出的是，DA3 法线计算前置前馈回归网络——法线先验首先由 DA3 独立计算完成，随后作为输入传入前馈网络，网络在此基础上进行微量修正和完整旋转构造（详见 III-D.4 节）。

C. 前馈高斯回归网络

与 MVSplat 一类直接从多视图图像恢复高斯参数的方法不同，本文关注的是在候选点已经由上游几何模块确定的条件下，学习从上下文特征输入 ctx 与几何先

验输入 $\mathbf{g}$ 到 surfel 参数的映射。对于当前关键帧筛选得到的 N_t 个候选点，记 ctx_i 为点 i 的上下文特征输入， $\mathbf{g}_i$ 为其几何先验输入，则前馈网络的目标可写为：

$$f_{\theta} : \{(\text{ctx}_i, \mathbf{g}_i)\}_{i=1}^{N_t} \mapsto \{(\mathbf{s}_i, \mathbf{q}_i, \alpha_i, \mathbf{c}_i^{\text{dc}}, \mathbf{c}_i^{\text{rest}})\}_{i=1}^{N_t}, \quad (1)$$

其中输出分别对应 surfel 的二维尺度、旋转、不透明度以及 SH 颜色参数。

1) 上下文特征输入 ctx ：与 pixelSplat、MVSplat 等需要同时恢复几何与外观的离线方法不同，本文候选点位置已由上游几何模块确定，网络只需围绕每个候选点构造逐点对齐的多视图上下文。共享 backbone（沿用 pixelSplat 设计，训练时冻结）分别对当前帧原始图像、当前帧渲染图像以及滑窗内 W 帧历史关键帧的原始与渲染图像提取特征图。其中渲染图像使网络能显式感知当前地图的重建状态，其与原始图像的差异隐式反映欠重建程度。对每个候选点，系统以其像素坐标在上述特征图上双线性插值采样，并计算归一化观察方向，得到当前帧逐点特征 $\mathbf{f}_i^{\text{curr}}, \mathbf{f}_i^{\text{en}} \in \mathbb{R}^D$ 及历史帧特征 $\mathbf{f}_i^{\text{hist}} \in \mathbb{R}^{W \times D}$ ；不可见的历史视角由可见性掩码 $\mathbf{m}_i^{\text{hist}} \in \{0, 1\}^W$ 标记。随后，系统使用跨注意力模块将可变长度的历史观测压缩为固定维度的时序上下文，其




图 2. 上下文感知前馈高斯回归器结构。网络首先在滑动窗口内对有效候选种子构造逐点对齐的上下文，并通过冻结的共享主干提取当前帧与历史帧的图像-渲染特征；随后，跨注意力模块汇聚多视图外观信息，并与逆深度、DA3 法线和位置编码等几何先验一起输入残差 MLP 编码器；最后，多头约束解码器预测完整的 2DGS surfel 属性 (μ, s, α, c, q) ，其中法线引导的旋转分支通过 Gram-Schmidt 正交化构造几何一致的朝向。

中不可见视角在 softmax 前以 $-\infty$ 掩码排除：

$$\text{ctx}_i^{\text{attn}} = \text{softmax}\left(\frac{\mathbf{q}_i \mathbf{K}_i^\top}{\sqrt{d_k}} + \mathbf{M}_i\right) \mathbf{V}_i \quad (2)$$

聚合完成后，当前帧原始特征、渲染特征与 $\text{ctx}_i^{\text{attn}}$ 拼接，构成送入编码器的上下文特征 ctx_i 。

2) 几何先验输入 $\mathbf{g}$ ：几何先验输入由逆深度、DA3 相机空间法线、有效性掩码和 KNN 像素间距拼接得到：

$$\mathbf{g}_i = [\bar{z}_i^{-1} \|\mathbf{n}_i^{\text{cam}}\| m_i \|d_i^{\text{nn}}\]. \quad (3)$$

其中 $\bar{z}_i^{-1}$ 提供尺度恢复所需的深度信息， $\mathbf{n}_i^{\text{cam}}$ 为 surfel 朝向的法线锚点， m_i 标记几何先验是否有效， d_i^{nn} 刻画局部采样密度。各连续分量经 NeRF 风格位置编码后与 ctx_i 拼接，送入由一层线性投影和 4 个 pre-activation 残差块构成的编码器，输出 512 维隐变量 $\mathbf{h}_i$ 。

3) 回归器解码器：在共享隐变量 $\mathbf{h}_i$ 的基础上，系统使用多个独立预测头以 Linear $\rightarrow$ ReLU $\rightarrow$ Linear 的形式回归不同属性。各头输出并不直接作为最终高斯参数，而是结合上游几何先验进行约束解码，从而使预测结果更稳定地锚定在已有几何信息上。

a) 法线引导的旋转解码：系统不直接回归四元数，而是以 DA3 提供的相机空间法线 $\mathbf{n}_i^{\text{cam}}$ 为锚点，由网络预测修正量，并通过正交化过程构造完整旋转。网络首先预测法线修正向量 $\delta \mathbf{z}_i \in \mathbb{R}^3$ 、混合强度 $\lambda_i = \text{softplus}(\cdot) \in$

$\mathbb{R}_{>0}$ 以及辅助向量 $\mathbf{a}_i \in \mathbb{R}^3$ ，进而得到修正后的法线方向：

$$\mathbf{z}_i = \text{normalize}(\mathbf{n}_i^{\text{cam}} + \lambda_i \cdot \delta \mathbf{z}_i) \quad (4)$$

随后利用 Gram-Schmidt 正交化过程构造完整正交基：

$$\mathbf{y}_i = \text{normalize}(\mathbf{z}_i \times \mathbf{a}_i), \quad \mathbf{x}_i = \mathbf{y}_i \times \mathbf{z}_i. \quad (5)$$

最终，相机系旋转矩阵 $[\mathbf{x}_i \mid \mathbf{y}_i \mid \mathbf{z}_i]$ 经当前帧位姿 R_{wc} 转换到世界系，并转为四元数存储。

b) 密度自适应尺度解码：尺度头预测 surfel 在像素平面上的相对尺度，并通过局部点密度先验进行调节：

$$\mathbf{s}_i^{\text{pixel}} = \frac{d_i^{\text{nn}}}{2} \cdot \exp(\text{head}(\mathbf{h}_i)) \in \mathbb{R}_{>0}^2. \quad (6)$$

其中 d_i^{nn} 为候选点的 KNN 像素间距。最终世界空间尺度由

$$\mathbf{s}_i^{\text{world}} = \mathbf{s}_i^{\text{pixel}} / (\bar{z}_i^{-1} \cdot f) \quad (7)$$

恢复得到。该参数化避免了网络直接学习深度相关的绝对尺度，而只需学习与局部密度相关的相对尺度变化。

c) 颜色解码：DC 颜色头输出残差 $\Delta \mathbf{c}_i^{\text{dc}}$ ，并加到由单帧 RGB 观测转换得到的基础 SH 先验上，形成

$$\mathbf{c}_i^{\text{dc}} = \text{RGB2SH}(\mathbf{I}_i) + \Delta \mathbf{c}_i^{\text{dc}}. \quad (8)$$

高阶 SH 系数则由独立头直接预测。该残差设计使网络能够从合理的颜色先验出发，仅学习局部修正量。

d) 不透明度解码：不透明度头经 sigmoid 激活输出 $\alpha_i \in (0, 1)$ ，随后转为 logit 空间存储。

D. 自蒸馏训练

前馈网络的训练不依赖外部多视图标注数据集，而是通过以下自蒸馏管线完成。

1) 在线数据采集：系统首先以 **naive** 模式（不使用前馈网络，而采用基于规则的初始化）在训练场景上运行一次完整的增量式建图。运行过程中，当某帧新增高斯的累积训练次数达到预设阈值时，系统快照这些高斯在该时刻的属性作为监督信号；与此同时，将它们投影到当前滑动窗口中，按照前文定义构造对应的上下文特征输入 ctx_i 与几何先验输入 $\mathbf{g}_i$ 。

因此，采集产物以高斯为核心单位组织，每个训练样本都可直接写成前文定义的输入输出对 $(\text{ctx}_i, \mathbf{g}_i) \mapsto (\mathbf{s}_i, \mathbf{q}_i, \alpha_i, \mathbf{c}_i^{\text{dc}}, \mathbf{c}_i^{\text{rest}})$ 。

2) 尺度-旋转歧义消解：2DGS surfel 存在固有的尺度-旋转歧义：交换两个切线方向的尺度并相应旋转 90° 可得到等价表示。若不消解此歧义，训练标签中同一几何形态会对应两种不同的参数组合，导致网络学习不稳定。

数据准备阶段显式消解此歧义：对每个 GT 高斯，强制 $s_1 \geq s_2$ ；当需要交换时，同步对四元数施加 90° 旋转： $\mathbf{q}' = \text{normalize}((w - z, x + y, y - x, w + z)/\sqrt{2})$ 。

3) 训练目标：网络以多任务损失联合训练，涵盖尺度、旋转、颜色和不透明度全部预测属性。尺度损失在 log 世界尺度空间以 L1 距离度量；旋转损失采用四元数余弦距离 $\mathcal{L}_{\text{rot}} = 1 - |\langle \mathbf{q}_{\text{pred}}, \mathbf{q}_{\text{gt}} \rangle|$ ；颜色损失对 DC 和高阶 SH 系数分别以 MSE 监督；不透明度损失为 L1 距离。

IV. 实验结果

A. 实验设置

我们主要从两方面验证所提方法的有效性：其一，在公开 R3LIVE (Avia) 数据集、MCD (OS1-64) 数据集及我们在东南大学四牌楼校区 (Avia) 的自建数据集上与现有增量式高斯建图方法进行渲染质量的定量与定性对比；其二，在 `hku_campus_seq_00` 上开展前馈回归器的消融分析，重点考察其对新高斯初始化质量与有限优化预算下早期收敛行为的影响。对于新视角渲染

质量，我们采用 PSNR、SSIM 和 LPIPS 作为评价指标。所有方法均在相同数据划分下进行评测，序列中的非训练帧用于序列内新视角评估。为保证比较公平性，所有方法在每个序列上的总优化步数均统一限制为该序列图像帧数的 20 倍。

所有实验均在统一硬件与软件环境下完成系统部署、网络训练以及新场景测试评估。实验平台采用 Ubuntu 20.04 (Python 3.8) 环境，基于 PyTorch 2.0.0 与 CUDA 11.8 实现。硬件配置为单张 RTX 4090D (24GB) GPU、16 vCPU Intel(R) Xeon(R) Platinum 8481C 处理器以及 80GB 系统内存。

前馈回归网络的训练数据来自 R3LIVE 的 `hku_campus_seq_02`、`hku_campus_seq_03`、`hkust_campus_seq_02`、`hkust_campus_seq_03` 以及我们的自建数据集 `seu_campus_seq_02`、`seu_campus_seq_03`。训练采用 Adam 优化器，batch size 设为 8192（逐点级），并配合梯度裁剪以保证训练稳定。学习率统一设置为 5×10^{-4} ，训练总计 150 个 epoch。损失项权重设置为 $\lambda_{\text{scale}} = 1.0$ 、 $\lambda_{\text{rot}} = 1.0$ 、 $\lambda_{\text{dc}} = 1.0$ 、 $\lambda_{\text{rest}} = 0.1$ 、 $\lambda_{\text{opac}} = 1.0$ 。上下文窗口大小被设置为 15。

对比方法包括 MonoGS、MM3DGS-SLAM、Gaussian-LIC-2。其中，由于 Gaussian-LIC-2 未开源完整版本，因此在 R3LIVE 和 MCD 数据集上的基线方法数据来自 Gaussian-LIC-2 论文；在我们的自建数据集上以及定性渲染图片对比中，MonoGS 被设置为纯视觉模式；MM3DGS-SLAM 被设置为 RGB-D 模式，我们通过将 lidar 点投影到图像上形成伪 RGB-D 数据；我们使用 2026.2.21 开源的 Gaussian-LIC-2。

B. 与现有方法的对比

表 I 给出了 R3LIVE (Avia)、MCD (OS1-64) 以及自建数据集上的定量结果，以看到本文方法几乎在全部测试序列上取得了最优的渲染指标。从不同方法的表现来看，纯视觉的 MonoGS 在大尺度室外与退化场景中容易出现明显的模糊、漂浮和结构崩塌，这说明仅依赖后续优化来修正不准确初始化是十分困难的；使用伪 RGB-D 数据的 MM3DGS-SLAM 拥有更好的效果，但是其各向同性和视角无关的高斯分布在有限的优化次数下表现不佳；使用 SPNet 补点策略后，Gaussian-LIC-2 成功重建了 LiDAR 从未扫描的区域，整体结果已有明显提升，但其新高斯属性仍主要依赖规则设计，

表 I

公开 R3LIVE (Avia)、MCD (OS1-64) 以及自建校园数据集上的序列内新视角 RGB 渲染结果对比。评价格式为 PSNR $\uparrow$ SSIM $\uparrow$ LPIPS $\downarrow$ 。

序列	渲染性能 (PSNR↑ SSIM↑ LPIPS↓)														
	MonoGS [18]				MM3DGS-SLAM [20]				Gaussian-LIC-2				Ours		
R3LIVE (Avia)															
degenerate_seq_00	14.59	0.460	0.624		19.35	0.698	0.212		21.99	0.782	0.162	23.41	0.821	0.137	
degenerate_seq_01	14.66	0.438	0.692		18.57	0.621	0.277		22.94	0.790	0.159	23.54	0.810	0.157	
hku_campus_00	15.41	0.464	0.675		18.70	0.621	0.319		24.34	0.787	0.156	25.52	0.820	0.152	
hku_campus_01	8.39	0.065	0.873		16.97	0.593	0.271		20.52	0.674	0.236	23.15	0.754	0.174	
hku_park_00	13.24	0.319	0.733		14.98	0.363	0.396		17.17	0.469	0.340	17.80	0.491	0.331	
hku_park_01	12.22	0.289	0.790		15.79	0.392	0.409		19.46	0.529	0.325	20.65	0.580	0.248	
MCD (OS1-64)															
tuhh_day_02	8.72	0.158	0.893		11.15	0.478	0.350		20.35	0.626	0.262	20.99	0.652	0.249	
tuhh_day_03	8.09	0.136	0.896		11.36	0.542	0.301		21.38	0.672	0.229	21.82	0.688	0.238	
tuhh_day_04	11.73	0.250	0.805		13.86	0.384	0.398		19.27	0.528	0.310	19.07	0.506	0.309	
Self-Collected Campus Dataset															
seu_campus_seq_00	14.56	0.411	0.732		18.54	0.563	0.366		23.97	0.769	0.215	25.55	0.830	0.145	
seu_campus_seq_01	13.21	0.392	0.796		17.14	0.528	0.421		22.76	0.711	0.195	24.56	0.797	0.161	

因而在有限的优化次数下，高亮区域、边界区域和未充分观测区域中依然存在拖影、过度平滑或局部失真。相比之下，本文方法利用当前帧与历史帧的图像渲染上下文，能够在插入时为 surfel 提供更接近收敛状态的属性初始化，因此在后续少量优化下即可获得更稳定的外观与更清晰的结构。

图 3 给出了三组具有代表性的定性结果。对于 `hku_campus_00` 中的室内外过渡场景，MonoGS 几乎无法恢复稳定结构，MM3DGS-SLAM 仍存在较明显的过度平滑和边界变钝，而 Gaussian-LIC-2 虽然重建出主要几何轮廓，但在强曝光出口附近以及右侧立柱区域仍有明显模糊；相比之下，本文方法能够更好地保持地面砖块纹理和立柱轮廓。在 `degenerate_seq_00` 场景中，MonoGS 出现了大面积塌陷与错误颜色聚集，MM3DGS-SLAM 虽然恢复出更多结构，但在困难区域仍存在失真，Gaussian-LIC-2 在左下角高亮区域依然表现出较强拖影。在自建的 `seu_campus_seq_01` 场景中，MonoGS 的结果存在明显模糊与结构退化，MM3DGS-SLAM 虽然恢复出更完整的布局，但远处建筑边缘的细节仍明显缺失，而 Gaussian-LIC-2 在建筑立面边界和地面纹理区域仍存在平滑与局部失真。相比之下，本文方法在三组场景中都表现出更好的整体清晰度、结构锐利度与局部一致性。

表 II

前馈回归器消融实验结果 (`HKU_CAMPUS_00`)。统计基于全部训练帧的优化轨迹：前两行给出 16 轮优化时的 MEAN $\pm$ STD；中两行为前 16 轮的 AUC；后两行为达到指定质量阈值所需优化轮数的 MEAN $\pm$ STD，括号中给出成功达到阈值的帧数。

设置	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
Baseline (16 轮)	23.97 $\pm$ 2.91	0.800 $\pm$ 0.071	0.213 $\pm$ 0.055
Ours (16 轮)	24.34 $\pm$ 2.74	0.813 $\pm$ 0.063	0.195 $\pm$ 0.048
Baseline (AUC@16)	362.96 $\pm$ 44.54	12.251 $\pm$ 1.302	4.266 $\pm$ 0.978
Ours (AUC@16)	370.57 $\pm$ 40.43	12.475 $\pm$ 1.149	4.033 $\pm$ 0.866
Baseline (time-to-quality)	20.4 $\pm$ 28.1 (255/391)	3.2 $\pm$ 6.2 (373/391)	27.0 $\pm$ 24.5 (257/391)
Ours (time-to-quality)	17.7 $\pm$ 26.0 (281/391)	3.1 $\pm$ 10.2 (382/391)	19.6 $\pm$ 15.6 (323/391)

C. 消融实验：前馈回归器的作用

为验证前馈回归器对增量式 2DGS 建图的贡献，我们在 `hku_campus_00` 序列上进行了消融实验。这里将“不使用回归器、直接采用基于规则初始化”的系统记为 **Baseline**，将“加入上下文感知前馈回归器”的系统记为 **Ours**。与仅挑选少量代表帧做数值比较不同，这里对全部训练帧的优化轨迹进行统计，并以高斯插入后的局部优化次数 (`train_times`) 作为横轴，从三个角度评估回归器的作用：1) 在固定优化预算下的早期质量；2) 前 16 轮内的整体收敛收益；3) 达到给定质量阈值所需的优化轮数。其中，给定质量中 PSNR、SSIM 和 LPIPS 的阈值分别设为 25.0、0.70 和 0.18。

表 II 表明，引入前馈回归器后，训练帧上的整体




图 3. 公开数据集与自建数据集上的定性对比结果。第一行为 `hku_campus_00` 序列第 690 帧，第二行为 `degenerate_seq_00` 序列第 516 帧，第三行为 `seu_campus_seq_01` 序列第 1080 帧。相较于 MonoGS、MM3DGS-SLAM 与 Gaussian-LIC-2，本文方法在结构边界、地面纹理以及远处区域保留了更清晰的细节，同时显著减轻了模糊、拖影与局部失真现象。




图 4. 前馈回归器消融的早期收敛对比。图中从左到右分别给出了插入前后 16 次局部优化内的 PSNR、SSIM 和 LPIPS 均值曲线，用于补充展示 Baseline 与 Ours 在早期阶段的收敛差异。

早期收敛行为得到稳定改善。首先，在固定的 16 轮局部优化预算下，Ours 在三个渲染指标一级 AUC 统计上均优于 Baseline，且 Ours 在三个指标上都能以更少的平均优化轮数达到目标质量，且在三个阈值下的成功覆盖帧数也均高于 Baseline。图 4 进一步汇总了插入前后 16 次局部优化内三项指标的均值收敛趋势。

从图 5 和图 6 的完整可视化结果直观说明了回归器为何能够提升早期收敛速度。在不使用回归器时，初始插入的高斯参数主要由手工规则给出，往往呈现出较强的离散性与无序性，因此需要依赖后续多轮优化逐步与场景对齐；而加入回归器后，即使在 0 次优化时，也已经可以观察到更为合理的场景布局和主体结构。进一

步从这些代表帧的可视化结果来看，回归器对不同区域表现出较为明确的自适应倾向：在欠重建或覆盖不足的区域，预测结果通常对应更具覆盖性的高斯配置，从而有助于快速补全主体结构；而在已经形成较好几何支撑或细节较为丰富的区域，预测结果则更倾向于保留较细粒度的高斯分布，以避免过度覆盖细节。类似地，在弱纹理或大面积平滑区域，回归器往往给出尺度相对更大的高斯以提升早期覆盖效率；而在纹理变化更丰富、结构边界更密集的区域，预测高斯通常更小、更集中，从而更有利于细节表达。尽管这些现象仍主要来自定性观察，但它们与本文的设计目标是一致的，即根据局部上下文直接回归更适合当前区域状态的初始高斯属性。随着优化轮数增加，本文方法能够更快收敛到清晰、稳定的渲染结果。

综合上述实验可以得到两个结论。首先，在完整的新视角渲染评估中，本文方法在所有测试序列上均优于现有基线，说明 2DGS 表示与上下文感知前馈插入的结合能够稳定提升增量式高斯地图的渲染质量。其次，前馈回归器的核心价值并不只是带来略高的最终指标，更重要的是显著改善新高斯插入后的初始质量和早期收敛速度。这一点对于在线系统尤为关键，因为更好的初始高斯不仅能减少局部伪影，还能为后续帧提供更可靠的渲染监督，从而形成正向循环，持续提升整张地图

的建图质量。

V. 结论

本文面向增量式场景重建中“新高斯初始化质量决定后续地图累积效果”这一问题，提出了一种基于 2DGS surfel 的上下文感知前馈高斯回归系统。该方法以上下文特征输入 $\mathbf{ctx}$ 和几何先验输入 $\mathbf{g}$ 为条件，在插入阶段直接预测新 surfel 的完整属性，从而替代传统基于规则的初始化；同时，网络可通过自蒸馏训练，无需额外标注数据。

在 R3LIVE 与 MCD 数据集上的实验表明，所提方法能够稳定提升增量式高斯地图的新视角渲染质量，其中相较于最接近的多传感器基线，在 R3LIVE 上平均提升 1.28 dB PSNR。消融实验进一步说明，该方法的主要收益来自对新 surfel 初始状态与早期收敛质量的改善，这一特性对于受限优化预算下的在线建图尤为重要。当前方法仍依赖外部稳定前端，未来将进一步探索更弱先验条件下的增量式高斯建图。

附录

前馈回归器消融可视化结果




图 5. 前馈回归器消融的可视化结果 (I)。展示 `hku_campus_00` 中代表帧 `train_0004` 与 `train_0084` 在 0、4、8 次局部优化后的渲染结果。对于每个代表帧，上两行为 Baseline，下两行为 Ours。



图 6. 前馈回归器消融的可视化结果 (II)。展示代表帧 `train_0609` 与 `train_0784` 在不同局部优化次数下的对比结果。与图 5 一致, 该图用于补充说明前馈初始化对后续早期收敛的影响。