

# Geometry-Guided Feed-Forward Regression for LiDAR-Inertial-Camera Photo-Realistic 2DGS Mapping

**摘要**—增量式三维场景重建要求系统在逐帧接收新观测的同时持续扩展地图，而有限的在线优化预算使得新插入高斯的初始属性质量直接影响地图的累积效果。现有基于 3D Gaussian Splatting 的增量式建图系统在表示与初始化两方面仍存在不足：三维椭球原语缺乏显式的表面法线语义，基于规则的初始化策略也难以充分利用外部几何先验。针对这两个相互关联的问题，本文提出了一种面向增量式 2DGS 场景重建的上下文感知前馈高斯回归系统。系统以 2DGS surfel 为地图基础表示，融合 SPNet 深度补全与单目法线先验构造候选点及其几何方向；前馈回归网络通过跨注意力机制聚合当前帧与历史帧的图像-渲染上下文，并以法线先验为锚点经 Gram-Schmidt 正交化构造 surfel 旋转，在单次前向传播中直接预测 surfel 属性。网络训练通过自蒸馏训练完成，无需外部标注数据集。在 R3LIVE 和 MCD 数据集上的实验表明，本文方法在全部测试序列上均优于现有基线，较最近的多传感器增量高斯建图基线平均提升 1.28 dB PSNR；消融实验进一步验证了前馈回归器在有限优化预算下对新高斯早期收敛质量的稳定改善。

## I. INTRODUCTION

增量式三维场景重建在灾害救援、自动驾驶与工业巡检等时效性强的现场任务中具有重要需求。近年来，LiDAR-惯导-视觉融合的增量式高斯建图系统已在大尺度室外场景中展现出在线照片级重建的能力：外部前端提供稳定位姿与多模态观测，后端以高斯原语逐帧扩展地图。然而，在线系统每帧的优化预算有限，新插入的高斯往往仅经历少量优化即需服务于后续帧的渲染，其初始属性质量直接影响地图的累积建图效果。

现有系统在地图后端的表示与初始化两方面仍存在相互关联的不足。表示层面，标准 3DGS 以三维椭球为基础原语，缺乏显式的表面法线语义，限制了几何先验与地图表示的直接耦合；2DGS 已通过将高斯压缩为二维有向盘面在几何质量上取得显著进步，但尚未被引入增量式建图。初始化层面，现有系统普遍采用基于规则的策略为新高斯赋予属性，导致新高斯需要较多优化步数收敛，与有限的逐帧预算矛盾；虽然已有系统引入

深度补全缓解 LiDAR 覆盖不足，但学习型先验仅用于确定补点位置，尚未扩展到属性全面预测。若表示缺乏几何可解释性，规则初始化便难以有效利用外部先验；而缺少学习型属性预测，表面化表示的优势也无法在插入阶段充分兑现。

针对上述问题，本文提出一种面向增量式 2DGS 场景重建的上下文感知前馈高斯回归系统。系统以 2DGS surfel 为地图表示，在外部 LIVO 前端提供位姿的条件下，融合深度补全与单目法线先验构造候选点及其几何方向；前馈回归网络聚合当前帧与滑动窗口内历史帧的图像-渲染图上下文，在单次前向传播中直接预测新高斯的完整 surfel 属性，随后纳入在线优化。网络训练通过我们构建的一套自蒸馏训练方法完成，无需外部标注数据集。

本文的主要贡献如下：

- 基于 2DGS surfel 的几何感知增量式高斯地图后端。不同于以 3DGS 体高斯为默认表示的现有增量系统，本文引入表面化的 2DGS 表示，使地图天然具备显式法线语义，从而能够直接耦合深度补全与法线先验，为前馈初始化提供几何可解释的表示基础。
- 上下文感知的前馈高斯插入方法。不同于依赖规则逐一赋值的传统初始化方式，本文通过前馈网络以逐点跨注意力融合多视角上下文，并以法线先验为锚点，在单次前向传播中直接预测完整 surfel 属性，使新高斯在插入时就更接近收敛状态，显著减少有限优化预算下的早期质量损失。
- 面向在线增量建图的自蒸馏训练。前馈网络无需外部标注数据集，仅从系统自身在训练场景上的增量建图过程中采集监督信号以训练网络。




图 1. 系统整体流程。(A) 外部 LiDAR-惯导-视觉前端提供同步的 RGB 图像、LiDAR 观测、IMU 信息和相机位姿。(B) 系统利用 SPNet 深度补全和 DA3 法线估计生成稠密几何先验，并与 LiDAR 点共同形成欠重建区域的初始点。(C) 对于每个候选点，前馈高斯回归器聚合逐点对齐的多视图上下文，直接预测 2DGS surfel 属性。(D) 预测得到的新 surfel 被插入增量地图后，再结合在线优化进一步更新；同时，当前地图的渲染结果继续作为后续插点的上下文输入。

## II. RELATED WORKS

NeRF 及其后续工作证明了辐射场表示在新视角合成和连续外观建模中的优势，但基于体渲染的采样与积分过程代价较高，难以直接满足实时增量式重建的需求。3D Gaussian Splatting (3DGS) 以显式高斯原语和可微光栅化替代体积分，在渲染速度和优化效率上取得了明显优势，因此很快成为在线照片级建图的重要基础表示。

围绕 3DGS, 已有研究从两个方向持续推进。一类工作关注几何质量, 例如 2D Gaussian Splatting (2DGS)、GaussianSurfels 和 PGSR 等方法通过表面化高斯、深度栅格化和法线约束增强几何一致性, 这类工作说明, 显式表面方向比 3D 椭球更适合承载深度和法线等几何先验, 为突破高斯表示的瓶颈提供了新的思路, 对后续增量式系统尤为关键。另一类工作则关注前馈式高斯先验, 例如 pixelSplat、MVSplat 和 MVSGaussian 等。这些方法通过概率采样或 cost volume 等机制, 从少量输入图像直接预测可泛化的高斯表示。尽管它们主要面向离线或一次性多视图重建, 但其输出所体现的几何与外观先验, 为在线系统中的初始化和补全提供了新的可能。

在在线建图方面, MonoGS、GS-SLAM、SplaTAM、

Photo-SLAM 等工作已经成功地证明了 3DGS 可以作为单目在线系统的统一地图表示, 将跟踪、建图和渲染耦合在同一高斯地图上, 但是这些工作仅针对室内场景。在大尺度户外场景中, LiDAR-Inertial-Camera 融合为增量式高斯建图提供了更稳定的位姿和几何观测。Gaussian-LIC 利用 LiDAR 点和视觉三角化点初始化 3DGS 地图, GS-LIVM 与 GS-LIVO 进一步考虑稀疏 LiDAR、局部窗口优化和资源约束, Gaussian-LIC2 则引入深度补全先验改善高斯初始化。这些工作与本文问题设定最接近, 但它们仍主要采用 3DGS 后端, 学习型先验也多用于补点或补深度, 没有进一步预测尺度、方向、颜色和不透明度等完整属性。本文在 LIVO 前端提供位姿的条件下, 将 2DGS surfel 作为地图表示, 并通过前馈网络一次性预测新 surfel 的完整属性, 从而改善增量插入阶段的初始质量。

## III. METHOD

### A. 系统概述

本系统是一个基于外部位姿前端的增量式 2DGS 场景重建后端。系统接收外部 LiDAR-Inertial-Camera 前端 (如 R3Live) 实时输出的同步数据流, 每帧包含 RGB 图像、稀疏 LiDAR 点云和 6-DOF 相机位姿, 以 2DGS surfel 为基础地图表示。整体流程如图 1 所示。

当新关键帧到达时，系统首先优化该相机位姿，即通过将已有高斯渲染至当前帧图像上，通过光度误差优化当前帧位姿。然后，系统插入新高斯并优化已有高斯：系统将稀疏 LiDAR 点投影到图像平面形成稀疏深度图，经 SPNet 深度补全后在 LiDAR 盲区生成补充初始 3D 点；与此同时，DA3 单目深度估计模型预测稠密相对深度并与由 LiDAR 点得到的稀疏绝对深度对齐，由此为初始点提供法线先验。在初始点生成后，系统对当前高斯地图进行渲染，依据渲染透明度和颜色误差识别欠重建区域，并结合颜色梯度过滤与体素下采样，从中筛选出确需新增高斯的候选点子集。随后，系统以这些候选点作为掩码 (mask) 对特征图与法线图进行过滤，提取出点对齐 (point-aligned) 的特征，由此构造出前馈回归网络所需的两类输入：上下文特征  $\mathbf{ctx}$  与几何先验  $\mathbf{g}$ 。该网络通过跨注意力机制融合多视角上下文，在单次前向传播中直接回归每个候选点的完整 surfel 属性，预测出的高质量新高斯插入地图。随后系统抽取关键帧进行在线优化，以光度损失  $\mathcal{L}_{\text{photo}}$  和几何约束损失 ( $\mathcal{L}_{\text{dist}}$  与  $\mathcal{L}_{\text{normal}}$ ) 联合驱动高斯属性收敛。非关键帧仅接收位姿而不触发高斯插入。

前馈回归网络通过自蒸馏方式训练，无需依赖外部标注数据。其核心思想是在训练场景上利用系统自身在线优化后的高斯结果构造监督信号，使网络能够学习更好的新 surfel 初始化策略。

### B. 稠密几何先验

采用 SPNet 轻量级深度补全网络将 RGB 图像与稀疏 LiDAR 深度融合为稠密深度图，并在无 LiDAR 覆盖的区域采样补充 3D 初始点。最终，SPNet 补充点与原始 LiDAR 投影点合并构成初始点集。

相较于直接由 SPNet 补全深度求导获得法线，DA3 具有更强的场景结构先验，能够提供更平滑、稳定的表面方向估计。因此，本文使用 DA3 对当前帧 RGB 图像推理输出相对深度图，并通过最小二乘仿射对齐将其与稀疏 LiDAR 深度配准，得到与真实尺度一致的稠密深度图；随后以中心差分计算逐像素法线。按初始点的像素坐标在法线图上采样，得到每个初始点的相机空间法线  $\mathbf{n}_{\text{cam}} \in \mathbb{R}^3$ 。

### C. 前馈高斯回归网络

如图 2 所示，本文的前馈高斯回归器以候选点为中心组织输入与预测流程。具体而言，系统首先利用当前

地图的  $\alpha$ -渲染结果定位欠重建区域，并据此对深度补全结果进行筛选，得到当前关键帧中的候选点；随后，围绕每个候选点聚合多视图上下文特征，并结合其几何先验，经共享编码器与多头解码器输出完整 surfel 属性。与 MV3Splat 一类直接在图像网格上预测高斯参数的方法不同，本文考虑的场景中，候选点已由上游几何模块预先确定。因此，本文的目标不是学习从多视图图像到像素对齐 (pixel-aligned) surfel 的稠密映射，而是以当前关键帧筛选得到的  $N_t$  个候选点为预测单元，在多视图特征图上为每个候选点采样并聚合其对应上下文，进而学习从点对齐 (point-aligned) 的上下文特征  $\mathbf{ctx}$  与几何先验  $\mathbf{g}$  到 surfel 参数的映射。记  $\mathbf{ctx}_i$  为候选点  $i$  的上下文特征输入， $\mathbf{g}_i$  为其几何先验输入，则前馈网络的目标可写为：

$$f_{\theta} : \{(\mathbf{ctx}_i, \mathbf{g}_i)\}_{i=1}^{N_t} \mapsto \{(\mathbf{s}_i, \mathbf{q}_i, \alpha_i, \mathbf{c}_i^{\text{dc}}, \mathbf{c}_i^{\text{rest}})\}_{i=1}^{N_t}, \quad (1)$$

其中输出分别对应 surfel 的二维尺度、旋转、不透明度以及 SH 颜色参数。

1) 上下文特征输入  $\mathbf{ctx}$ ：共享 backbone (沿用 pixelSplat 设计，训练时冻结) 分别对当前帧原始图像、当前帧渲染图像以及滑窗内  $W$  帧历史关键帧的原始与渲染图像提取特征图。其中，由于单视角观测对 surfel 属性回归的约束有限，本文引入滑动窗口内的历史关键帧以提供多视图上下文；渲染图像使回归器能显式感知当前地图的重建状态，其与原始图像的差异隐式反映欠重建程度。对每个候选点，系统将其投影到当前帧与各历史关键帧，在对应像素位置对上述特征图进行双线性插值采样，并计算归一化观察方向；随后，将原始图像特征、渲染图像特征与编码后的观察方向向量拼接，得到当前帧逐点特征  $\mathbf{f}_i^{\text{curr}} \in \mathbb{R}^D$ 。类似地，对滑窗内  $W$  帧可见视角执行相同操作，得到历史帧特征  $\mathbf{f}_i^{\text{hist}} \in \mathbb{R}^{W \times D}$ ，其中不可见的历史视角由可见性掩码  $\mathbf{m}_i^{\text{hist}} \in \{0, 1\}^W$  标记。随后，系统使用跨注意力模块将可变长度的历史观测压缩为固定维度的时序上下文，其中不可见视角在 softmax 前以  $-\infty$  掩码排除：

$$\mathbf{ctx}_i^{\text{attn}} = \text{softmax}\left(\frac{\mathbf{q}_i \mathbf{K}_i^{\top}}{\sqrt{d_k}} + \mathbf{M}_i\right) \mathbf{V}_i \quad (2)$$

聚合完成后，当前帧特征  $\mathbf{f}_i^{\text{curr}}$  与上下文特征  $\mathbf{ctx}_i^{\text{attn}}$  拼接，构成送入编码器的上下文特征  $\hat{\mathbf{ctx}}_i$ 。

2) 几何先验输入  $\mathbf{g}$ ：几何先验输入由逆深度、DA3 相




图 2. 上下文感知前馈高斯回归器结构。网络首先在滑动窗口内对有效候选点构造逐点对齐的上下文，并通过冻结的共享主干提取当前帧与历史帧的图像-渲染特征；随后，跨注意力模块汇聚多视图外观信息，并与逆深度、DA3 法线和位置编码等几何先验一起输入残差 MLP 编码器；最后，多头约束解码器预测 2DGS surfel 属性  $(s, \alpha, c, q)$ ，其中法线引导的旋转分支通过 Gram-Schmidt 正交化构造几何一致的朝向。

机空间法线、有效性掩码和 KNN 像素间距拼接得到： 交基：

$$\mathbf{g}_i = [\bar{z}_i^{-1} \|\mathbf{n}_i^{\text{cam}}\| m_i \|d_i^{\text{nn}}\]. \quad (3) \quad \mathbf{y}_i = \text{normalize}(\mathbf{z}_i \times \mathbf{a}_i), \quad \mathbf{x}_i = \mathbf{y}_i \times \mathbf{z}_i. \quad (5)$$

其中  $\bar{z}_i^{-1}$  提供尺度恢复所需的深度信息， $\mathbf{n}_i^{\text{cam}}$  为 surfel 朝向的法线锚点， $m_i$  标记几何先验是否有效， $d_i^{\text{nn}}$  刻画局部采样密度。各连续分量经 NeRF 风格位置编码后与  $\text{ctx}_i$  拼接，送入由一层线性投影和 4 个 pre-activation 残差块构成的编码器，输出 512 维隐变量  $\mathbf{h}_i$ 。

3) 回归器解码器：在共享隐变量  $\mathbf{h}_i$  的基础上，系统使用多个独立预测头以 Linear  $\rightarrow$  ReLU  $\rightarrow$  Linear 的形式回归不同属性。各头输出并不直接作为最终高斯参数，而是结合上游几何先验进行约束解码，从而使预测结果更稳定地锚定在已有几何信息上。

a) 法线引导的旋转解码：系统不直接回归四元数，而是以 DA3 提供的相机空间法线  $\mathbf{n}_i^{\text{cam}}$  为锚点，由网络预测修正量，并通过正交化过程构造完整旋转。网络首先预测法线修正向量  $\delta \mathbf{z}_i \in \mathbb{R}^3$ 、混合强度  $\lambda_i = \text{softplus}(\cdot) \in \mathbb{R}_{>0}$  以及辅助向量  $\mathbf{a}_i \in \mathbb{R}^3$ ，进而得到修正后的法线方向：

$$\mathbf{z}_i = \text{normalize}(\mathbf{n}_i^{\text{cam}} + \lambda_i \cdot \delta \mathbf{z}_i) \quad (4)$$

随后利用 Gram-Schmidt 正交化过程构造完整正

最终，相机系旋转矩阵  $[\mathbf{x}_i | \mathbf{y}_i | \mathbf{z}_i]$  经当前帧位姿  $R_{\text{wc}}$  转换到世界系，并转为四元数存储。

b) 密度自适应尺度解码：尺度头预测 surfel 在像素平面上的相对尺度，并通过局部点密度先验进行调节：

$$\mathbf{s}_i^{\text{pixel}} = \frac{d_i^{\text{nn}}}{2} \cdot \exp(\text{head}(\mathbf{h}_i)) \in \mathbb{R}_{>0}^2. \quad (6)$$

其中  $d_i^{\text{nn}}$  为候选点的 KNN 像素间距。最终世界空间尺度由

$$\mathbf{s}_i^{\text{world}} = \mathbf{s}_i^{\text{pixel}} / (\bar{z}_i^{-1} \cdot f) \quad (7)$$

恢复得到。该参数化避免了网络直接学习深度相关的绝对尺度，而只需学习与局部密度相关的相对尺度变化。

c) 颜色解码：DC 颜色头输出残差  $\Delta \mathbf{c}_i^{\text{dc}}$ ，并加到由单帧 RGB 观测转换得到的基础 SH 先验上，形成

$$\mathbf{c}_i^{\text{dc}} = \text{RGB2SH}(\mathbf{I}_i) + \Delta \mathbf{c}_i^{\text{dc}}. \quad (8)$$

高阶 SH 系数则由独立头直接预测。该残差设计使网络能够从合理的颜色先验出发，仅学习局部修正量。

d) 不透明度解码：不透明度头经 sigmoid 激活输出  $\alpha_i \in (0, 1)$ ，随后转为 logit 空间存储。

#### D. 自蒸馏训练

前馈网络的训练不依赖外部多视图标注数据集，而是通过以下自蒸馏管线完成。

1) 在线数据采集：系统首先以 **naive** 模式（不使用前馈网络，而采用基于规则的初始化）在训练场景上运行一次完整的增量式建图。运行过程中，当某帧新增高斯的累积训练次数达到预设阈值时，系统快照这些高斯在该时刻的属性作为监督信号；与此同时，将它们投影到当前滑动窗口中，按照前文定义构造对应的上下文特征输入  $\text{ctx}_i$  与几何先验输入  $\mathbf{g}_i$ 。

因此，采集产物以高斯为核心单位组织，每个训练样本都可直接写成前文定义的输入输出对  $(\text{ctx}_i, \mathbf{g}_i) \mapsto (\mathbf{s}_i, \mathbf{q}_i, \alpha_i, \mathbf{c}_i^{\text{dc}}, \mathbf{c}_i^{\text{rest}})$ 。

2) 尺度-旋转歧义消解：2DGS surfel 存在固有的尺度-旋转歧义：交换两个切线方向的尺度并相应旋转  $90^\circ$  可得到等价表示。若不消解此歧义，训练标签中同一几何形态会对应两种不同的参数组合，导致网络学习不稳定。

数据准备阶段显式消解此歧义：对每个 GT 高斯，强制  $s_1 \geq s_2$ ；当需要交换时，同步对四元数施加  $90^\circ$  旋转： $\mathbf{q}' = \text{normalize}((w - z, x + y, y - x, w + z)/\sqrt{2})$ 。

3) 训练目标：网络以多任务损失联合训练，涵盖尺度、旋转、颜色和不透明度全部预测属性。尺度损失在 log 世界尺度空间以 L1 距离度量；旋转损失采用四元数余弦距离  $\mathcal{L}_{\text{rot}} = 1 - |\langle \mathbf{q}_{\text{pred}}, \mathbf{q}_{\text{gt}} \rangle|$ ；颜色损失对 DC 和高阶 SH 系数分别以 MSE 监督；不透明度损失为 L1 距离。

### IV. EXPERIMENTAL RESULTS

#### A. 实验设置

我们主要从两方面验证所提方法的有效性：其一，在公开 R3LIVE (Avia) 数据集、MCD (OS1-64) 数据集及我们在东南大学四牌楼校区的自建数据集（采集硬件为 Livox Avia LiDAR 与 Hikvision MV-CA013-21UC RGB 相机，以及 LiDAR 内置的 200 Hz IMU）上与现有增量式高斯建图方法进行渲染质量的定量与定性对比；其二，在 `hku_campus_seq_00` 上开展前馈回归器的消融分析，重点考察其对新高斯初始化质量与有限优化预算下早期收敛行为的影响。对于新视角渲染质量，我们采用 PSNR、SSIM 和 LPIPS 作为评价指标。所有方法均在相同数据划分下进行评测，序列中的非训练帧用于序列内新视角评估。为保证比较公平性，所有方法

在每个序列上的总优化步数均统一限制为不超过该序列图像帧数的 20 倍。

所有实验均在统一硬件与软件环境下完成系统部署、网络训练以及新场景测试评估。实验平台采用 Ubuntu 20.04 (Python 3.8) 环境，基于 PyTorch 2.0.0 与 CUDA 11.8 实现。硬件配置为单张 RTX 4090D (24GB) GPU、16 vCPU Intel(R) Xeon(R) Platinum 8481C 处理器以及 80GB 系统内存。

前馈回归网络的训练数据来自 R3LIVE 的 `hku_campus_seq_02`、`hku_campus_seq_03`、`hkust_campus_seq_02`、`hkust_campus_seq_03` 以及我们的自建数据集 `seu_campus_seq_02`、`seu_campus_seq_03`。训练采用 Adam 优化器，batch size 设为 8192（逐点级），并配合梯度裁剪以保证训练稳定。学习率统一设置为  $5 \times 10^{-4}$ ，训练总计 150 个 epoch。损失项权重设置为  $\lambda_{\text{scale}} = 1.0$ 、 $\lambda_{\text{rot}} = 1.0$ 、 $\lambda_{\text{dc}} = 1.0$ 、 $\lambda_{\text{rest}} = 0.1$ 、 $\lambda_{\text{opac}} = 1.0$ 。上下文窗口大小被设置为 15。

对比方法包括 MonoGS、MM3DGS-SLAM、Gaussian-LIC-2。在 R3LIVE 和 MCD 数据集上的基线方法数据来自 Gaussian-LIC-2 论文；在我们的自建数据集上以及定性渲染图片对比中，MonoGS 被设置为纯视觉模式；MM3DGS-SLAM 被设置为 RGB-D 模式，我们通过将 lidar 点投影到图像上形成伪 RGB-D 数据；Gaussian-LIC-2 使用 2026 年 2 月开源版。

#### B. 与现有方法的对比

表 I 给出了 R3LIVE (Avia)、MCD (OS1-64) 以及自建数据集 (Avia) 上的定量结果，以看到本文方法几乎在全部测试序列上取得了最优的渲染指标。从不同方法的表现来看，纯视觉的 MonoGS 在大尺度室外与退化场景中容易出现明显的模糊、漂浮和结构崩塌，这说明仅依赖后续优化来修正不准确初始化是十分困难的；使用伪 RGB-D 数据的 MM3DGS-SLAM 拥有更好的效果，但是其各向同性和视角无关的高斯分布在有限的优化次数下表现不佳；使用 SPNet 补点策略后，Gaussian-LIC-2 成功重建了 LiDAR 从未扫描的区域，整体结果已有明显提升，但其新高斯属性仍主要依赖规则设计，因而在有限的优化次数下，高亮区域、边界区域和未充分观测区域中依然存在拖影、过度平滑或局部失真。相比之下，本文方法利用当前帧与历史帧的图像-渲染上下文，能够在插入时为 surfel 提供更接近

表 I

公开 R3LIVE (Avia)、MCD (OS1-64) 以及自建校园数据集上的序列内新视角 RGB 渲染结果对比。评价格式为 PSNR $\uparrow$  SSIM $\uparrow$  LPIPS $\downarrow$ 。

| 序列                            | 渲染性能 (PSNR↑ SSIM↑ LPIPS↓) |       |       |  |                  |       |       |  |                |       |       |       |       |       |  |
|-------------------------------|---------------------------|-------|-------|--|------------------|-------|-------|--|----------------|-------|-------|-------|-------|-------|--|
|                               | MonoGS [18]               |       |       |  | MM3DGS-SLAM [20] |       |       |  | Gaussian-LIC-2 |       |       |       | Ours  |       |  |
| R3LIVE (Avia)                 |                           |       |       |  |                  |       |       |  |                |       |       |       |       |       |  |
| degenerate_seq_00             | 14.59                     | 0.460 | 0.624 |  | 19.35            | 0.698 | 0.212 |  | 21.99          | 0.782 | 0.162 | 23.41 | 0.821 | 0.137 |  |
| degenerate_seq_01             | 14.66                     | 0.438 | 0.692 |  | 18.57            | 0.621 | 0.277 |  | 22.94          | 0.790 | 0.159 | 23.54 | 0.810 | 0.157 |  |
| hku_campus_00                 | 15.41                     | 0.464 | 0.675 |  | 18.70            | 0.621 | 0.319 |  | 24.34          | 0.787 | 0.156 | 25.52 | 0.820 | 0.152 |  |
| hku_campus_01                 | 8.39                      | 0.065 | 0.873 |  | 16.97            | 0.593 | 0.271 |  | 20.52          | 0.674 | 0.236 | 23.15 | 0.754 | 0.174 |  |
| hku_park_00                   | 13.24                     | 0.319 | 0.733 |  | 14.98            | 0.363 | 0.396 |  | 17.17          | 0.469 | 0.340 | 17.80 | 0.491 | 0.331 |  |
| hku_park_01                   | 12.22                     | 0.289 | 0.790 |  | 15.79            | 0.392 | 0.409 |  | 19.46          | 0.529 | 0.325 | 20.65 | 0.580 | 0.248 |  |
| MCD (OS1-64)                  |                           |       |       |  |                  |       |       |  |                |       |       |       |       |       |  |
| tuhh_day_02                   | 8.72                      | 0.158 | 0.893 |  | 11.15            | 0.478 | 0.350 |  | 20.35          | 0.626 | 0.262 | 20.99 | 0.652 | 0.249 |  |
| tuhh_day_03                   | 8.09                      | 0.136 | 0.896 |  | 11.36            | 0.542 | 0.301 |  | 21.38          | 0.672 | 0.229 | 21.82 | 0.688 | 0.238 |  |
| tuhh_day_04                   | 11.73                     | 0.250 | 0.805 |  | 13.86            | 0.384 | 0.398 |  | 19.27          | 0.528 | 0.310 | 19.07 | 0.506 | 0.309 |  |
| Self-Collected Dataset (Avia) |                           |       |       |  |                  |       |       |  |                |       |       |       |       |       |  |
| seu_campus_seq_00             | 14.56                     | 0.411 | 0.732 |  | 18.54            | 0.563 | 0.366 |  | 23.97          | 0.769 | 0.215 | 25.55 | 0.830 | 0.145 |  |
| seu_campus_seq_01             | 13.21                     | 0.392 | 0.796 |  | 17.14            | 0.528 | 0.421 |  | 22.76          | 0.711 | 0.195 | 24.56 | 0.797 | 0.161 |  |

收敛状态的属性初始化,因此在后续少量优化下即可获得更稳定的外观与更清晰的结构。

### C. 消融实验: 前馈回归器的作用

为验证前馈回归器对增量式 2DGS 建图的贡献,我们在 `hku_campus_00` 序列上进行了消融实验。这里将“不使用回归器、直接采用基于规则初始化”的系统记为 **Baseline**,将“加入上下文感知前馈回归器”的系统记为 **Ours**。与仅挑选少量代表帧做数值比较不同,这里对全部训练帧的优化轨迹进行统计,并以高斯插入后的对当前帧的优化次数 (`train_times`) 作为横轴,从三个角度评估回归器的作用: 1) 在固定优化预算下的早期质量; 2) 前 16 轮内的整体收敛收益; 3) 达到给定质量阈值所需的优化轮数。其中,给定质量中 PSNR、SSIM 和 LPIPS 的阈值分别设为 25.0、0.70 和 0.18。

表 II 表明,引入前馈回归器后,训练帧上的整体早期收敛行为得到稳定改善。首先,在固定的 16 轮对当前帧的优化预算下, Ours 在三个渲染指标以及 AUC 统计上均优于 Baseline; 同时, Ours 在三个指标上都能以更少的平均优化轮数达到目标质量,且在三个阈值下的成功覆盖帧数也均高于 Baseline。表 III 进一步列出了插入后前 16 次对当前帧的优化内三项指标的均值收敛趋势。

表 II

前馈回归器消融实验结果 (`HKU_CAMPUS_00`)。统计基于全部训练帧的优化轨迹: 前两行给出 16 轮优化时的 MEAN  $\pm$  STD; 中两行为前 16 轮的 AUC; 后两行为达到指定质量阈值所需优化轮数的 MEAN  $\pm$  STD, 括号中给出成功达到阈值的帧数。

| 设置                         | PSNR $\uparrow$                             | SSIM $\uparrow$                            | LPIPS $\downarrow$                          |
|----------------------------|---------------------------------------------|--------------------------------------------|---------------------------------------------|
| Baseline (16 轮)            | 23.97 $\pm$ 2.91                            | 0.800 $\pm$ 0.071                          | 0.213 $\pm$ 0.055                           |
| Ours (16 轮)                | <b>24.34 <math>\pm</math> 2.74</b>          | <b>0.813 <math>\pm</math> 0.063</b>        | <b>0.195 <math>\pm</math> 0.048</b>         |
| Baseline (AUC@16)          | 362.96 $\pm$ 44.54                          | 12.251 $\pm$ 1.302                         | 4.266 $\pm$ 0.978                           |
| Ours (AUC@16)              | <b>370.57 <math>\pm</math> 40.43</b>        | <b>12.475 <math>\pm</math> 1.149</b>       | <b>4.033 <math>\pm</math> 0.866</b>         |
| Baseline (time-to-quality) | 20.4 $\pm$ 28.1 (255/391)                   | 3.2 $\pm$ 6.2 (373/391)                    | 27.0 $\pm$ 24.5 (257/391)                   |
| Ours (time-to-quality)     | <b>17.7 <math>\pm</math> 26.0 (281/391)</b> | <b>3.1 <math>\pm</math> 10.2 (382/391)</b> | <b>19.6 <math>\pm</math> 15.6 (323/391)</b> |

从图 4 的完整可视化结果直观说明了回归器为何能够提升早期收敛速度。在不使用回归器时,初始插入的高斯参数主要由手工规则给出,往往呈现出较强的离散性与无序性,因此需要依赖后续多轮优化逐步与场景对齐;而加入回归器后,即使在 0 次优化时,也已经可以观察到更为合理的场景布局和主体结构。进一步从这些代表帧的可视化结果来看,回归器对不同区域表现出较为明确的自适应倾向: 在欠重建或覆盖不足的区域,预测结果通常对应更具覆盖性的高斯配置,从而有助于快速补全主体结构;而在已经形成较好几何支撑或细节较为丰富的区域,预测结果则更倾向于保留较细粒度的高斯分布,以避免过度覆盖细节。类似地,在弱纹理或大面积平滑区域,回归器往往给出尺度相对更大的高斯




图 3. 公开数据集与自建数据集上的定性对比结果。第一行为 `hku_campus_00` 序列第 690 帧，第二行为 `degenerate_seq_00` 序列第 516 帧，第三行为 `seu_campus_seq_01` 序列第 1080 帧。相较于 MonoGS、MM3DGS-SLAM 与 Gaussian-LIC-2，本文方法在结构边界、地面纹理以及远处区域保留了更清晰的细节，同时显著减轻了模糊、拖影与局部失真现象。

Table III

EARLY CONVERGENCE OF THE FEED-FORWARD REGRESSOR ABLATION ON `HKU_CAMPUS_00`. VALUES ARE AVERAGED OVER VALID TRAINING FRAMES; BOLD INDICATES THE BETTER RESULT AT EACH STEP.

| Metric             | Method   | Steps after insertion |              |              |              |              |
|--------------------|----------|-----------------------|--------------|--------------|--------------|--------------|
|                    |          | 0                     | 4            | 8            | 12           | 16           |
| PSNR $\uparrow$    | Baseline | 18.18                 | 22.07        | 23.41        | 23.95        | 23.97        |
|                    | Ours     | <b>18.92</b>          | <b>22.83</b> | <b>23.83</b> | <b>24.20</b> | <b>24.34</b> |
| SSIM $\uparrow$    | Baseline | 0.636                 | 0.753        | 0.786        | 0.800        | 0.800        |
|                    | Ours     | <b>0.661</b>          | <b>0.772</b> | <b>0.797</b> | <b>0.810</b> | <b>0.813</b> |
| LPIPS $\downarrow$ | Baseline | 0.380                 | 0.291        | 0.248        | 0.226        | 0.213        |
|                    | Ours     | <b>0.366</b>          | <b>0.276</b> | <b>0.233</b> | <b>0.211</b> | <b>0.195</b> |

以提升早期覆盖效率；而在纹理变化更丰富、结构边界更密集的区域，预测高斯通常更小、更集中，从而更有利于细节表达。尽管这些现象仍主要来自定性观察，但它们与本文的设计目标是一致的，即根据局部上下文直接回归更适合当前区域状态的初始高斯属性。随着优化轮数增加，本文方法能够更快收敛到清晰、稳定的渲染结果。

综合上述实验可以得到两个结论。首先，在完整的新视角渲染评估中，本文方法在所有测试序列上均优于

现有基线，说明 2DGS 表示与上下文感知前馈插入的结合能够稳定提升增量式高斯地图的渲染质量。其次，前馈回归器的核心价值并不只是带来略高的最终指标，更重要的是显著改善新高斯插入后的初始质量和早期收敛速度。这一点对于在线系统尤为关键，因为更好的初始高斯不仅能减少局部伪影，还能为后续帧提供更可靠的渲染监督，从而形成正向循环，持续提升整张地图的建图质量。

## V. CONCLUSION

本文面向增量式场景重建中“新高斯初始化质量决定后续地图累积效果”这一问题，提出了一种基于 2DGS surfel 的上下文感知前馈高斯回归系统。该方法融合上下文信息与几何先验，在插入阶段直接预测新 surfel 属性，从而替代传统基于规则的初始化；同时，网络可通过自蒸馏训练，无需额外标注数据。

在 R3LIVE 与 MCD 数据集上的实验表明，所提方法能够稳定提升增量式高斯地图的新视角渲染质量，其中相较于最接近的多传感器基线，在 R3LIVE 上平均提升 1.28 dB PSNR。消融实验进一步说明，该方法的主要收益来自对新 surfel 初始状态与早期收敛质量的改善，这一特性对于受限优化预算下的在线建图尤为

重要。当前方法仍依赖外部稳定前端，未来将进一步探索更弱先验条件下的增量式高斯建图。




图 4. 前馈回归器消融的可视化结果。展示代表帧 train\_0004、train\_0084、train\_0609 与 train\_0784 在 0、4、8 次对当前帧的优化后的结果；每行左三列为 Baseline，右三列为 Ours。

REFERENCES